

Lab 4-1 Report — 20201068 이지호

1. What I did

스켈레톤의 네 TODO 블록(순전파, 역전파와 gradient check, 미니배치 학습 루프, 학습률 비교)을 명세 그대로 구현했고 함수 시그니처나 제공 헬퍼는 바꾸지 않았다. Figure 2는 발산한 실행이 보이도록 y축을 로그 스케일로 그렸다. 스켈레톤 밖의 추가 실험은 하나로, 5절의 근거를 위해 $lr=0.01$ 만 다른 조건을 그대로 둔 채 6000에폭까지 학습했다.

2. Results

Table 1. Gradient check. 처음 16개 학습 샘플에서 해석적 기울기와 중심차분 기울기의 상대오차 최댓값이 임계값 $1e-6$ 보다 한참 작으므로, 학습 곡선을 보기 전에 `backward()`가 올바르게 동작한다고 결론낼 수 있다.

Quantity	Value
max relative error, analytic vs numerical gradient	$9e-08$
pass threshold	$1e-6$

Table 2. Three learning rates, one split, one seed, one initialization. 발산한 실행을 가장 뚜렷하게 가르는 열은 Max train loss(19.4281 대 0.6853, 0.6247)이다. 발산한 실행의 마지막 에폭은 크게 진동하는 곡선 위의 임의의 한 점이라, Final train loss 만으로는 실행이 실패했는지 판단할 수 없다.

Learning rate	Final train loss	Max train loss	Final val loss	Final val accuracy	Best val accuracy
0.01	0.6065	0.6853	0.6049	0.7063	0.7063
1.0	0.2822	0.6247	0.3608	0.8812	0.8938
100.0	8.2030	19.4281	8.1166	0.7063	0.7063
majority-class baseline (validation split)	n/a	n/a	n/a	0.7063	n/a

3. Figures




Figure 1. The two press settings, coloured by outcome. 통과 샘플은 중앙의 직사각형 영역(온도 약 -0.65~0.6, 압력 약 -0.5~0.5)에 모여 있고, 그 밖에는 소수의 예외만 있다.




Figure 2. Training loss against epoch for three learning rates. $lr=0.01$ 은 거의 평평하고, $lr=1.0$ 은 약 30에폭의 정체 뒤 급락하며, $lr=100$ 은 학습 내내 크게 진동한다.




Figure 3. Decision boundary of the trained network. 경계(검은 선)는 Figure 1의 직사각형을 모서리가 둥근 닫힌 곡선으로 근사한다. 모서리와 사각형 밖의 소수 통과 샘플, 안쪽의 불량 샘플에서 틀린다.

4. Interpretation

은닉층이 필요한 이유. Figure 1의 통과 영역은 직사각형, 즉 온도와 압력 각각의 상한과 하한, 모두 네 개의 경계를 동시에 만족하는 영역이다. 직선 하나로는 이런 닫힌 영역을 둘러쌀 수 없지만, 은닉 유닛들이 각각 한 방향의 경계를 만들고 출력층이 이를 결합하면 Figure 3처럼 닫힌 경계가 만들어진다.

세 학습률. Figure 2에서 $lr=0.01$ 의 손실은 약 0.61에서 거의 움직이지 않는다. 이 값은 항상 양성 확률 0.296을 출력하는 모델의 교차엔트로피(약 0.607)와 같다. 즉 400에폭 동안 클래스 비율만 배웠고, 검증셋에서 양성을 하나도 예측하지 않는다(스텝이 너무 작다). $lr=1.0$ 도 같은 정체 구간을 지나지만 29에폭에 벗어나 0.28 부근까지 내려가고, 검증 정확도 0.8812를 얻었다(Table 2, 사용 가능한 크기). $lr=100$ 은 검증 정확도가 기준선과 같은 0.7063이다(너무 큰 스텝).

$lr=100$ 의 손실. 이 실행의 손실은 두 포화값을 반복한다. 모든 샘플을 불량으로 확신하면 양성 샘플마다 클리핑된 로그 손실 $-\log(10^{-12}) \approx 27.63$ 을 받아 $0.2969 \times 27.63 \approx 8.20$ 이 되고(400에폭 중 150에폭), 모두 통과로 확신하면 $0.7031 \times 27.63 \approx 19.43$ 이 된다(15에폭, Table 2의 Max train loss). 출력층의 기울기 $a_2 - y$ 는 출력이 포화돼도 0이 되지 않아서, $lr=100$ 에서는 b_2 하나만 해도 한 번의 업데이트에 약 30(모두 불량일 때)에서 70(모두 통과일 때)씩 움직인다. 그래서 출력이 정답 쪽으로 조금 움직이는 대신 반대쪽 포화로 넘어간다. 손실이 1.0 아래(최저 0.63)로 내려오는 에폭도 13개 있다. 이 컴퓨터에서는 마지막 에폭이 8.20이었지만 발산한 실행의 마지막 값은 기계마다 다르므로, 이런 에폭에서 끝났다면 정상적인 손실처럼 보였을 것이다. 그래서 마지막 값이 아니라 Max train loss를 봐야 한다.

Gradient check의 가치. 역전파에서 $1/n$ 을 빠뜨려도 기울기의 방향은 그대로이고 크기만 배치 크기(32)배가 된다. 학습은 정상처럼 진행되지만 실효 학습률이 32배가 되어, Task 4의 학습률 비교가 구현 오류와 섞인다. Table 1의 오차 $9e-08$ 은 이런 오류가 없음을 학습 전에 보여 주므로, 세 실행의 차이를 학습률 탓으로 돌릴 수 있다.

5. Limitations

" $lr=0.01$ 은 너무 작다"는 결론은 400에폭 예산에 묶여 있다. 같은 조건에서 6000에폭까지 학습하면 $lr=0.01$ 도 3003에폭에 정체 구간을 벗어나($lr=1.0$ 의 29에폭보다 약 100배 늦음) 검증 정확도 0.8688에 도달한다. 즉 0.01은 학습이 안 되는 값이 아니라 100배 느린 값이고, 에폭 예산이 바뀌면 결론도 바뀐다. 또 하나의 분할, 하나의 시드, 세 개의 학습률만 썼으므로 1.0과 100 사이 어디서 발산이 시작되는지는 알 수 없다.

AI & external-code usage

Tool / Source	Part used for	What I modified & verified myself
Claude	Concept explanations, API/syntax lookup.	설명과 API 사용법을 concept note와 대조해 확인.
Claude Code	Debugging advice, official docs.	제안을 직접 반영하고 공개 테스트 6개 통과와 gradient check 최대 상대오차 $9e-08$ 을 실행으로 확인.