

Lab 4-2 Report — 20201068 이지호

1. What I did

스켈레톤의 네 TODO 블록(모델, 학습/평가 한 예폭, 조기 종료 루프, 하이퍼파라미터 그리드)을 명세대로 구현했고 함수 시그니처와 제공 헬퍼는 바꾸지 않았다. 스켈레톤 밖의 추가 실험은 하나로, 4절의 근거를 위해 선택된 설정 (hidden 32, lr 0.1)을 조기 종료 없이 80에폭까지 학습했다(테스트셋은 쓰지 않음). 결과는 `python src/lab04_2.py`를 두 번 실행해 `runtime_seconds`를 제외하고 완전히 같음을 확인했다.

2. Results

Table 1. Six configurations scored on validation, one of them scored on test. 선택된 행은 검증 손실이 가장 작은 hidden size 32, learning rate 0.1(강조 표시)이고, 다른 열이 아니라 검증 손실(0.335632)을 기준으로 골랐다.

Hidden size	Learning rate	Best epoch	Epochs run	Validation loss	Validation accuracy
8	0.01	80	80	0.600035	0.7000
8	0.1	52	62	0.352824	0.8675
8	1.0	15	25	0.362131	0.8500
32	0.01	80	80	0.592339	0.7000
32	0.1	43	53	0.335632	0.8550
32	1.0	20	30	0.360808	0.8575

Selected configuration: hidden size 32, learning rate 0.1.

Test loss 0.370398, test accuracy 0.8475 (measured once, after the table above was complete). 다수 클래스 기준선은 테스트 0.7025, 검증 0.700이다.

3. Figures




Figure 1. Training and validation loss of the selected configuration. 두 곡선은 약 30에폭 이후 벌어지기 시작하고(학습 손실은 계속 내려가고 검증 손실은 오르내림), 조기 종료는 검증 손실이 가장 낮은 43에폭을 유지했다.




Figure 2. Validation loss across the grid. 학습률이 손실을 훨씬 크게 움직인다. 학습률 0.01에서 0.1로 바꾸면 약 0.25 줄지만, 같은 학습률에서 hidden size를 8에서 32로 바꾸면 최대 약 0.017 줄 뿐이다.




Figure 3. Validation against test for the selected configuration. 같은 가중치에서 테스트 손실(0.3704)이 검증 손실(0.3356)보다 약 0.035 높고, 정확도는 0.8550에서 0.8475로 0.0075 낮다.

4. Interpretation

기준선과 같은 두 행. Table 1에서 학습률 0.01인 두 행(hidden 8, 32)의 검증 정확도는 모두 0.7000으로, 검증 분할에서 항상 "서비스 불필요"로 답하는 모델의 정확도와 같다. 실제로 두 모델은 검증셋에서 양성을 하나도 예측하지 않는다. 그렇다고 학습이 멈춘 것은 아니다. 두 행의 검증 손실(0.600, 0.592)은 항상 양성 확률 0.3을 출력하는 모델의 교차 엔트로피(약 0.611)보다 낮고, 최선 예폭이 마지막 80예폭이라 끝까지 내려가고 있었다. 학습률이 작아 80예폭 안에 어떤 logit도 0을 넘을 만큼 움직이지 못했을 뿐이다.

조기 종료. Figure 1의 선택된 설정을 80예폭 끝까지 돌려 확인하면 검증 손실이 43예폭의 0.3356에서 80예폭의 0.3516으로 올라가고 학습 손실은 0.3085까지 내려간다. 즉 예산을 모두 쓰면 과적합된 가중치를 얻었을 것이고, 조기 종료와 최선 가중치 복원이 이를 막았다.

검증 손실로 고르는 이유. 위 두 행은 정확도로는 0.7000으로 같지만 손실로는 구분된다. 정확도는 logit이 0을 넘었는지만 세트로 문턱을 넘기 전의 진전이나 확신도의 차이를 보지 못하고, 400개 검증셋에서 한 건에 0.25%p씩 움직이는 거친 값이다. 정확도가 가장 높은 hidden 8, 학습률 0.1(0.8675)도 선택된 설정(0.8550)과 5개 차이일 뿐이다. 손실은 모든 샘플의 확신도를 반영하는 연속값이라 이런 작은 차이에 덜 흔들리므로 선택 기준으로 더 안정적이다.

테스트가 검증보다 나쁜 이유. 선택된 설정과 예폭은 여섯 설정, 각 설정의 모든 예폭 중 검증 손실이 가장 낮은 것으로 골랐다. Figure 1에서 검증 손실은 28예폭부터 0.34~0.35 사이에서 평평하게 오르내리고, 43예폭의 0.3356은 그 안의 작은 골이다. 흔들리는 값들 중 최솟값을 고르면 그 값은 낙관적으로 치우친다(최솟값 선택 효과). 테스트셋은 선택에 쓰이지 않았으므로 Figure 3의 테스트 수치가 일반화 성능에 더 가까운 추정이다. 다만 정확도 차이 0.0075는 테스트 400개 중 3개라 잡음 수준이고, 차이는 손실(0.035)에서 더 분명하다.

5. Limitations

선택된 hidden size 32는 그리드의 가장자리(가장 큰 값)이고 학습률도 세 값뿐이라, 더 큰 모델이나 0.1과 1.0 사이의 학습률이 더 좋을 수 있다. 또한 400개짜리 단일 검증 분할이라 정확도 한 건이 0.25%p이고, 설정 사이의 작은 차이(예: 0.3356 대 0.3528)는 분할이 바뀌면 뒤집힐 수 있다.

AI & external-code usage

Tool / Source	Part used for	What I modified & verified myself
Claude	Concept explanations, API/syntax lookup.	설명과 API 사용법을 concept note와 대조해 확인.
Claude Code	Debugging advice, official docs.	제안을 직접 반영하고 공개 테스트 6개 통과와, python src/lab04_2.py 두 번 실행 결과가 runtime_seconds를 제외하고 동일함을 실행으로 확인.